

Perbandingan Inferensial vs Prediktif pada Data Abalone

Laporan hasil awal dan rancangan replikasi R • 28 September 2026

STATUS HASIL: seluruh angka empiris laporan ini dihitung dengan Python dari CSV unggahan. Pembagian data/fold mengikuti skrip R sumber, tetapi implementasi pohon/RF tidak identik. Ini bukan laporan hasil eksekusi R. R Markdown dan kode R disertakan untuk replikasi.


1. Pendahuluan dan tujuan

Proyek membandingkan tujuan inferensial dan prediktif pada Rings abalone. Inferensi menilai asosiasi dan ketidakpastian, sedangkan prediksi menilai galat pada observasi baru. Tidak diasumsikan bahwa signifikansi parameter atau kecocokan sampel otomatis menjamin akurasi prediksi (Shmueli, 2010). Pertanyaan utama: bagaimana kedua pendekatan saling melengkapi dalam pemodelan Rings berdasarkan morfologi?

2. Data dan kualitas awal

CSV berisi 4.177 abalone, delapan prediktor, dan target Rings. Komposisi Sex adalah M 1.528, I 1.342, F 1.307; I berarti infant. Tidak ada nilai kosong atau duplikat persis. Rings berkisar 1–29, rerata 9,934 dan simpangan baku sampel 3,224. Empat baris memenuhi aturan audit $\text{Height} \leq 0$ atau $> 0,3$; tetap dipakai dalam model utama.

Umur pendekatan = Rings + 1,5 tahun menurut UCI. Skala numerik CSV dipertahankan karena dokumentasi sumber memuat catatan penskalaan fitur kontinu. Data observasional ini tidak menjamin representasi seluruh populasi, dan sebagian pengukuran bobot bersifat destruktif (Nash et al., 1994).



Gambar 1. Distribusi Rings pada seluruh CSV. Perhitungan dan grafik: Python pendamping; $n = 4.177$.

3. Metode dan keterlacakan analisis

Jalur inferensial mengikuti skrip sumber: OLS sederhana Rings ~ Shell_weight pada seluruh data, dilanjutkan OLS berganda yang memasukkan Sex dan tujuh variabel numerik. Sex memakai acuan F. Uji $H_0: \beta_{\text{Shell}} = 0$ pada model sederhana menggunakan $\alpha = 0,05$; CI HC3 dilaporkan sebagai pendamping ketidakpastian. Model berganda bersifat eksploratif, bukan identifikasi efek kausal.

Jalur prediktif mempertahankan algoritme pembagian LCG Park–Miller, state awal 2026. Setelah skor diurutkan, 3.341 observasi masuk data latih dan 836 masuk data uji. Fold 1–5 disusun berulang pada urutan latih; model dilatih ulang setiap fold. Pemilihan berdasarkan RMSE gabungan prediksi OOF. Seluruh spesifikasi dibekukan sebelum membaca skor uji. Tidak ada tuning hiperparameter dalam analisis ini.

Komponen	R yang disediakan	Python yang dieksekusi
Rata-rata / OLS	Rerata, <code>lm()</code> sederhana dan berganda	Rerata, OLS <code>statsmodels</code> dengan desain setara
Sex	Faktor; acuan F untuk <code>lm</code>	Dua dummy <code>SexI</code> dan <code>SexM</code>
Pohon	<code>rpart: cp=0.005, minbucket=15, xval=0</code>	<code>DecisionTreeRegressor: min_samples_leaf=15</code> ; tanpa pemetaan <code>cp</code>
Random Forest	<code>randomForest: ntree=300, mtry=3</code>	<code>RandomForestRegressor: 300 pohon, max_features=3, min_samples_leaf=1</code>
Seed RF	2026+k di CV; 3030 final	2026+k di CV; 3030 final; generator/algoritme berbeda

Kesamaan seed tidak menjamin hasil pohon lintas perangkat lunak sama. Pengodean faktor dan algoritme split/pembentukan pohon berbeda (dokumentasi `randomForest`, `rpart.control`, dan `scikit-learn`). Karena itu tabel hasil berikut secara eksplisit disebut pendamping Python.

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2}$$

$$R_{uji}^2 = 1 - \frac{\sum_{i=1}^m (y_i - \hat{y}_i)^2}{\sum_{i=1}^m (y_i - \bar{y}_{uji})^2}$$

Diagnostik mencakup residual, Q–Q, VIF per kolom desain, Cook, serta sensitivitas empat baris Height. Tambahan bootstrap berpasangan 2.000 kali mengulang baris uji dengan model tetap untuk CI RMSE dan CI selisih RF – OLS berganda. CI tersebut kondisional, bukan interval prediksi individu.


4. Hasil inferensial dan diagnostik

$$\widehat{\text{Rings}} = 6.462116647 + 14.535675261 \text{ Shell_weight}$$

Ukuran model sederhana	Hasil
Kemiringan Shell_weight	14,5357
SE klasik / SE HC3	0,2791 / 0,3162
CI 95% HC3 kemiringan	[13,9158; 15,1556]
p kemiringan	< 0,001
R ² sederhana / berganda	0,3938 / 0,5379

Kenaikan 0,1 unit Shell_weight pada skala CSV berasosiasi dengan peningkatan rerata sekitar 1,454 Rings. Intersep tidak ditafsirkan sebagai umur nyata abalone dengan bobot nol. Model sederhana memuat asosiasi tidak teradjust; pada model berganda koefisien Shell_weight sekitar 8,7418 dengan CI HC3 [4,9515; 12,5321], setelah mengondisikan pada prediktor lain.

VIF maksimum adalah 109,77. Koefisien Height berubah dari 10,7615 pada semua data menjadi 23,4808 setelah empat baris audit dikeluarkan dalam analisis sensitivitas. CI HC3 Height pada model utama mencakup nol. Temuan ini tidak mendukung penafsiran mekanis setiap tanda koefisien sebagai efek biologis independen.



Gambar 2. Residual terhadap fitted regresi berganda seluruh data. Periksa pola rerata, ragam, dan titik berpengaruh sebelum menafsirkan koefisien.

HC3 membantu estimasi ketidakpastian terhadap ragam yang tidak konstan, tetapi tidak mengatasi perancu, ketergantungan observasi, dan bentuk hubungan yang kurang tepat. Q-Q dan Cook tersedia dalam dashboard/notebook. Tidak ada observasi yang dihapus otomatis dari analisis utama.

5. Hasil prediktif pendamping Python

Seluruh model pada tabel dilatih hanya pada data latih; data uji tidak dipakai mengestimasi koefisien prediktif. Tabel diurutkan menurut CV_RMSE, bukan Uji_RMSE. RMSE/MAE bersatuan Rings, sedangkan R^2 tidak berdimensi.

Model	CV RMSE	Uji MAE	Uji RMSE	Uji R^2
Random Forest	2,141	1,539	2,243	0,5452
Regresi berganda	2,222	1,549	2,214	0,5571
Pohon regresi	2,296	1,671	2,426	0,4681
Regresi sederhana	2,494	1,837	2,579	0,3989
Rata-rata	3,198	2,395	3,327	-0,0002

Tabel 1. Hasil pendamping Python. OLS sepadan secara matematis dengan formula sumber; hasil pohon/RF bukan replikasi eksekusi R.

RF memiliki CV_RMSE terkecil (2,1410), sehingga menjadi model pilihan CV. Pada data uji, OLS berganda mempunyai RMSE sedikit lebih rendah (2,2136) dibandingkan RF (2,2432), walaupun MAE RF sedikit lebih rendah. Perbedaan peringkat antar-metrik dan antar-sampel tidak boleh disembunyikan atau digunakan untuk memilih ulang setelah membuka data uji.

5.1 Ketidakpastian RMSE uji

Model	RMSE uji	CI bootstrap 95%
Rata-rata	3,327	[3,062; 3,593]
Regresi sederhana	2,579	[2,361; 2,788]
Regresi berganda	2,214	[2,032; 2,390]
Pohon regresi	2,426	[2,222; 2,625]
Random Forest	2,243	[2,038; 2,438]

Selisih RMSE RF – OLS berganda adalah 0,0296 Rings, dengan CI bootstrap berpasangan 95% $[-0,0602; 0,1260]$. Interval mencakup nol; perbandingan ini tidak memberi dasar kuat untuk klaim keunggulan pasti salah satu model. Bootstrap tidak melatih ulang model dan tidak mencakup variasi proses pelatihan.

5.2 Makna praktis hasil

Model berganda dan RF sama-sama mengurangi galat dibandingkan prediksi rerata latih. Regresi lebih langsung memberikan parameter asosiasi, sedangkan RF memberi pembanding nonlinier. Kesimpulan yang defensibel adalah saling melengkapi, bukan kemenangan mutlak satu pendekatan. Keputusan operasional tetap memerlukan informasi biaya pengukuran, toleransi galat, serta validasi eksternal.

6. Kesimpulan, keterbatasan, dan reproduksi

Dalam model sederhana, Shell_weight berasosiasi positif dengan Rings dan CI HC3 tidak mencakup nol. Model berganda menunjukkan kecocokan sampel lebih tinggi, tetapi multikolinearitas dan sensitivitas Height membatasi interpretasi masing-masing koefisien. Pada pendamping Python, RF dipilih dari CV, sedangkan OLS berganda sedikit lebih baik pada RMSE uji. CI selisih yang mencakup nol tidak mendukung klaim keunggulan pasti.

Inferensi dan prediksi memberikan jenis bukti yang berbeda. Kesimpulan inferensial dibatasi pada asosiasi observasional; kesimpulan prediktif dibatasi pada evaluasi internal terhadap data sejenis. Dataset tidak menyediakan metadata memadai untuk menguji pengelompokan/lokasi, dan tidak semua prediktor dapat diukur secara nondestruktif. Umur hasil konversi Rings bukan kebenaran biologis yang terukur langsung.

6.1 Keterlacakan hasil

Source code dan manifest split/fold disertakan. Notebook R menjalankan ulang analisis; dashboard offline menampilkan model pendamping Python yang telah dihitung. Perbaikan jalur Windows pada skrip asli, pembungkusan fungsi, paket wajib, VIF, bootstrap, ekspor model, dan dashboard tercatat sebagai perubahan. Tidak ada data simulasi yang diperlakukan sebagai data pengamatan.

```
source("00_Instal_Paket.R")
source("01_Analisis_Abalone.R")
hasil <- analisis_abalone()
rmarkdown::render("02_Notebook_Abalone.Rmd")
shiny::runApp(".")
```

Sebelum mengubah laporan menjadi “hasil R”, jalankan kode tersebut, ganti tabel dari folder hasil_R, perbarui peringkat serta kesimpulannya, dan cantumkan sessionInfo. Hasil Python tidak otomatis menjadi angka yang akan dihasilkan randomForest R.

Referensi ringkas

Nash, W., Sellers, T., Talbot, S., Cawthorn, A., & Ford, W. (1994). Abalone [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C55C7W.

Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310. DOI: 10.1214/10-STS330.

Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32. DOI: 10.1023/A:1010933404324.

R Core Team. Dokumentasi lm dan rpart.control. stat.ethz.ch/R-manual/R-devel/library/stats/html/lm.html; stat.ethz.ch/R-manual/R-devel/library/rpart/html/rpart.control.html. Diakses 28 September 2026.

Liaw, A., & Wiener, M. Dokumentasi paket randomForest. stat.ethz.ch/CRAN/web/packages/randomForest/refman/randomForest.html. Diakses 28 September 2026.

Perangkat pendamping: statsmodels (OLS/HC3), scikit-learn (pohon/RF), NumPy/pandas; versi terdapat pada hasil_python/versi_dan_status.json. Sumber primer tugas: CSV, skrip R, dan gambar instruksi unggahan pengguna.